KNN

Teoria

W statystyce algorytm ***k* -najbliższych sąsiadów** (***k* -NN**) jest nieparametryczną metodą. Służy do klasyfikacji i regresji . W obu przypadkach dane wejściowe składają się z *k* najbliższych przykładów uczących w zbiorze danych . Wynik zależy od tego, czy *k* -NN jest używane do klasyfikacji czy regresji:

- W *klasyfikacji k-NN* wynikiem jest przynależność do klasy. Obiekt jest klasyfikowany na podstawie wielu głosów jego sąsiadów, przy czym obiekt jest przypisywany do klasy najczęściej występującej wśród jego *k* najbliższych sąsiadów (*k* jest dodatnią liczbą całkowitą , zwykle małą). Jeśli *k* = 1, to obiekt jest po prostu przypisywany do klasy tego najbliższego sąsiada.

- W *regresji k-NN* wynikiem jest wartość właściwości obiektu. Ta wartość jest średnią z wartości *k* najbliższych sąsiadów. Jeśli *k* = 1, to wyjście jest po prostu przypisywane do wartości tego pojedynczego najbliższego sąsiada.

k -NN to typ klasyfikacji , w którym funkcja jest aproksymowana tylko lokalnie, a wszystkie obliczenia są odraczane do czasu oceny funkcji. Ponieważ ten algorytm opiera się na klasyfikacji na odległości, jeśli cechy reprezentują różne jednostki fizyczne lub występują w bardzo różnych skalach, normalizacja danych treningowych może radykalnie poprawić ich dokładność.

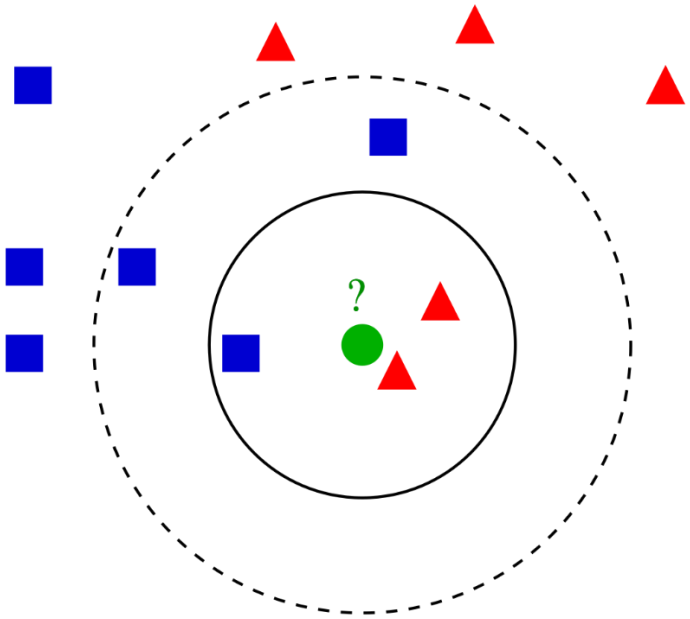

Przykład klasyfikacji k -NN. Próbkę testową (zielona kropka) należy podzielić na niebieskie kwadraty lub czerwone trójkąty. Jeśli k = 3 (ciągła linia koła) jest przypisane do czerwonych trójkątów, ponieważ wewnątrz wewnętrznego koła są 2 trójkąty i tylko 1 kwadrat. Jeśli k = 5 (przerywana linia okręgu), jest przypisany do niebieskich kwadratów (3 kwadraty vs. 2 trójkąty wewnątrz zewnętrznego koła).

Klasyfikator ważony

Zarówno w przypadku klasyfikacji, jak i regresji użyteczną techniką może być przypisanie wag wkładom sąsiadów, tak aby bliżsi sąsiedzi mieli większy wkład w średnią niż bardziej odlegli. Na przykład powszechny schemat ważenia polega na przypisywaniu każdemu sąsiadowi wagi 1/ *d* , gdzie *d* jest odległością do sąsiada.

Metryka Euklidesowa

W matematyce **odległość euklidesowa** między dwoma punktami w przestrzeni euklidesowej to długość odcinka między tymi dwoma punktami . Można ją obliczyć ze współrzędnych kartezjańskich punktów za pomocą twierdzenia Pitagorasa , dlatego czasami nazywa się ją **odległością Pitagorasa.**

Dla punktów podanych przez współrzędne kartezjańskie w n-wymiarowa przestrzeń euklidesowa, odległość wynosi:

$$d(p,q) = \sqrt{(p_1 - q_1)^2 + (p_2 - q_2)^2 + \cdots + (p_n - q_n)^2}.$$

Metryka Manhattan

Geometria **Manhattanu** to geometria , której zwykła funkcja odległości lub metryka geometrii euklidesowej została zastąpiona nową metryką, w której odległość między dwoma punktami jest sumą bezwzględnych różnic ich współrzędnych kartezjańskich.

$$d_{\mathrm{T}}(\mathbf{p},\mathbf{q}) = \|\mathbf{p}-\mathbf{q}\|_{\mathrm{T}} = \sum_{i=1}^{n} |p_i - q_i|$$

Na przykład w$\mathbb{R}^2$, odległość taksówki między$\mathbf{p} = (p_1, p_2)$i$\mathbf{q} = (q_1, q_2)$Jest$|p_1 - q_1| + |p_2 - q_2|$.

Projekt

Pomocne narzędzia: scikit-learn, numpy, pandas

1. Pobieranie zbioru danych

   from sklearn import load_iris – zbiór 3-klasowy, można wyeliminować jedną z klas, można też działać na wszystkich

2. Podział danych na zbiór treningowy i testowy

   Jednym ze sposobów jest np. użycie funkcji train_test_split – Należy losowo wyselekcjonować próbkę treningową i testową – optymalny podział w tym przypadku to 70% dla treningu, i 30% dla testu
   Od zbioru testowego należy oddzielić atrybuty decyzyjne – czyli klasy – i przechowywać je w odrębnej liście. Ze zbioru treningowego też można te klasy oddzielić, ale nie trzeba – wystarczy pamiętać, żeby ostatniej kolumny nie uwzględniać w obliczeniach.

3. Klasyfikator

   KNN jest to funkcja, która zwraca tablicę (listę), zawierającą klasy przewidywane dla danego zbioru danych. W naszej sytuacji przekazywać będziemy liczbę całkowitą reprezentującą liczbę *k* sąsiadów, z których zaczerpniemy naszą decyzję, nasz zbiór testowy (bez klasy decyzjyjnej) do ponownej klasyfikacji, oraz zbiór treningowy. Zbiór treningowy służy naszemu klasyfikatorowi jako jego baza wiedzy, i do jego elementów porównywane będą elementy ze zbioru testowego.
   Na początku wykonywania funkcji należy zainicjować listę o długości zbioru testowego – w niej będziemy przechowywać przewidziane klasy, i ją będziemy zwracać na końcu funkcji. Następnie tworzymy pętlę iterującą po wszystkich wierszach zbioru testowego. W tej pętli tworzymy nową listę o długości zbioru treningowego – w niej będziemy przechowywać odległości naszego elementu testowego do elementów zbioru treningowego. Następnie będziemy wyliczać te dystanse (w pętli iterującej po obiektach treningowych) i zapisywać je do tej listy.

   Metody obliczania dystansu nazywamy metrykami. Przykładami najpopularniejszych metryk są:
   - Dystans euklidesowy
   - Metryka Manhattan
   - Metryka cosinusowa

Przy obliczaniu dystansu traktujemy każdy z atrybutów jako wymiar. W wypadku datasetu iris operujemy w czterech wymiarach.

Po obliczeniu odległości danego obiektu testowego do wszystkich obiektów zbioru treningowego należy odnaleźć k obiektów treningowych o najkrótszych dystansach, i sprawdzić ich klasy. Najczęstsza z tych klas zostanie naszą klasą przewidzianą dla danego obiektu testowego, i

zapisana zostanie na liście przewidzianych klas (tej, którą utworzyliśmy na samym początku funkcji). Jeżeli przekazaliśmy klasy decyzyjne zbioru treningowego jako odrębny argument, pomocna może się okazać funkcja argsort z biblioteki NumPy. Zwraca ona listę indeksów danej tablicy posortowaną względem jej wartości.

Po ustaleniu klasy dla każdego obiektu testowego i zapisaniu każdej z nich do listy, kończymy działanie funkcji, zwracając tą listę.

Po zakończeniu działania funkcji sprawdzamy dokładność naszego klasyfikatora. W tym celu porównujemy elementy listy zwróconej przez funkcję z decyzjami, które oddzieliliśmy od naszego zbioru testowego. Dla zbioru iris przy k=3 wyniki dla każdej z metryk wymienionej powyżej powinny wynosić około 90%, natomiast zdarza się, że metryka cosinusowa osiągnie nawet 100%.

Kryteria oceny

Im bardziej rozbudowany klasyfikator KNN tym wyższą ocenę można uzyskać.

1 metryka , podstawowy KNN – ocena 3

2 metryki, podstawowy KNN – ocena 3.5

3 metryki, podstawowy KNN – ocena 4

2 metryki, KNN ważony – ocena 4.5

3 metryki, KNN ważony – ocena 5

Swoje rozwiązania proszę przesyłać w formacie .html lub .py

Każdy z państwa musi wywiązać się z projektu tj. zaprezentować go: zasada działania, krótki opis co zostało zrobione, omówienie wyników. Bez prezentacji projekty nie będą zaliczone. Prezentacji można dokonać w dowolnym momencie na zajęciach.